Safra Sentinela

Alerta de quebra de safra para a agricultura familiar do Semiárido

EQUIPE

Arthur Evangelista Thomazini
RM562260

Elom Eduardo Maio Nascimento
RM564921

Henrique Soares Meira
RM565646

Luiz Phelipe Silva Menezes Araujo
RM566417 · aluno responsável

Raphael Martins Teixeira Amaral
RM562664

Global Solution 2026/2 · CitizenTech
Turma 2TSCOA · Grupo RHEAL (Grupo 42)

No Semiárido, uma estação de chuva ruim leva a safra da família

Território: 1.477 municípios do Semiárido brasileiro, onde feijão e milho dependem só da chuva

60%

das lavouras municipais de feijão e milho tiveram quebra na seca de 2012

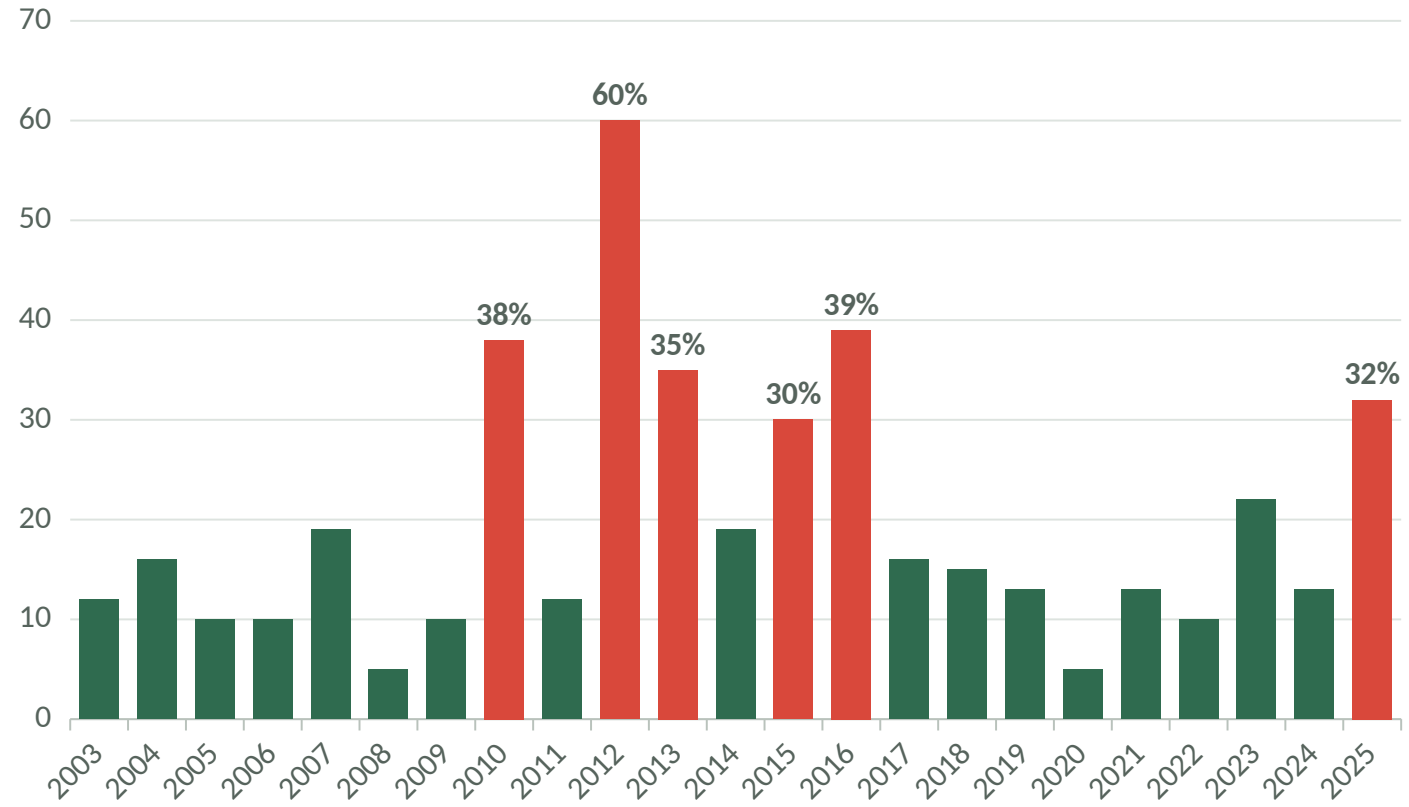
1,2 mi ha

plantados em 2012 não chegaram a ser colhidos

64%

dos municípios tiveram ao menos uma quebra entre 2020 e 2025

Lavouras municipais com quebra de safra, por ano (%)



Fonte: IBGE, Produção Agrícola Municipal (2000–2025). Quebra = rendimento abaixo de 50% da média dos 5 anos anteriores do município. Em vermelho, anos com 30% ou mais.

Para quem: Dona Francisca, agricultora familiar no Cariri paraibano



Dona Francisca, 52 anos

Monteiro (PB) · 4 hectares de milho e feijão
Planta com a família, sem irrigação
Celular simples, sinal só na sede do sítio

"Eu só fico sabendo que a safra não vinga quando já plantei tudo."

Do que ela precisa

Saber cedo se o ano é de risco para a lavoura

Orientação prática: o que fazer agora

Acesso ao técnico e ao seguro a tempo

O que dificulta hoje

Decide só pela experiência e pela conversa com vizinhos

Previsões do tempo são genéricas e difíceis de entender

Internet instável e pouca prática com aplicativos

A ajuda oficial chega meses depois da perda

Persona ilustrativa, construída a partir do perfil da agricultura familiar de sequeiro no Semiárido.

Quem é beneficiado e quem faz a solução funcionar

QUEM USA E É BENEFICIADO

Agricultores familiares

Recebem o aviso de risco e orientações simples no celular ou pelo rádio.

Técnicos de extensão rural

Veem o mapa e a lista de municípios para visitar primeiro.

Gestores públicos

Antecipam sementes, assistência e o Garantia-Safra onde o risco é maior.

QUEM PARTICIPA DO ECOSSISTEMA

IBGE e NASA

Dados abertos de produção agrícola e de clima por satélite.

Sindicatos e cooperativas

Cadastram os agricultores e dão credibilidade ao aviso.

Rádios comunitárias

Levam o alerta a quem não tem celular ou sinal.

Operadoras e WhatsApp

Canal de entrega das mensagens de texto e áudio.

A solução: do satélite ao celular do agricultor em três passos

1 Medir

Chuva, temperatura e umidade do solo medidas por satélite, mais o histórico de safras de cada município.

2 Prever

Um modelo de Machine Learning estima a chance de quebra de safra por município e por cultura.

3 Avisar

O agricultor recebe um aviso simples; o técnico recebe o mapa de prioridades.

PRINCIPAIS FUNCIONALIDADES

- **Alerta no celular**

  WhatsApp, SMS e áudio, com três ações práticas.

- **Mapa de risco**

  Três níveis por município e lista de prioridades de visita.

- **Chuva quase em tempo real**

  Chuva de cada dia, com cerca de 3 dias de atraso.

- **Análises e assistente**

  Conferência com o resultado real e perguntas em linguagem simples.

Dados públicos entram, informação simples sai

DADOS UTILIZADOS

IBGE — Produção Agrícola Municipal

Área, produção e rendimento de feijão e milho, 2000–2025

NASA POWER

Clima mensal para o modelo e chuva diária para o acompanhamento

IBGE — delimitação do Semiárido

Lista oficial dos municípios atendidos

INFORMAÇÃO ENTREGUE

Nível de risco de quebra por município e cultura

O que fazer: guardar semente, procurar o técnico, conferir o seguro

Chuva recente: 30 e 90 dias, e dias seguidos sem chuva

Feita para quem tem pouco sinal, pouca leitura ou alguma deficiência

- **Sem internet:** versão SMS de até 160 caracteres
- **Sem leitura:** o mesmo aviso em áudio
- **Sem celular:** rádio comunitária e sindicato repassam o alerta
- **Sem aplicativo:** nada para instalar ou atualizar
- **Linguagem simples:** três ações numeradas, sem termos técnicos
- **Baixa visão e daltonismo:** ícone e texto junto da cor, alto contraste

Benefícios para as pessoas e como vamos medir o impacto

Para a família

Tempo para guardar semente e alimento, replantar ou acionar o seguro antes da perda.

Para técnicos e gestores

Visitas e recursos direcionados aos municípios de maior risco.

Para o território

Menos perdas, resposta mais rápida à seca e mais confiança na informação pública.

INDICADORES DE IMPACTO

Indicador	Situação atual
Quebras avisadas a tempo	60% no teste (2020–2025)
Alertas que se confirmam	31% no teste
Antecedência do aviso	fim da estação chuvosa, antes da colheita
Municípios cobertos	1.477 do Semiárido
Safra 2026 (previsão atual)	31% das 2.869 lavouras em risco alto
Famílias cadastradas e alcançadas	a medir no piloto
Mensagens lidas ou ouvidas	a medir no piloto

Quebras avisadas e alertas confirmados: teste do modelo (2020–2025). A safra de 2026 ainda não tem resultado oficial.

Contribuição para os Objetivos de Desenvolvimento Sustentável

2

ODS 2 — Fome zero e agricultura sustentável

Protege a produção de alimentos e a renda de pequenos produtores (metas 2.3 e 2.4): o aviso permite reagir antes de a safra se perder.

13

ODS 13 — Ação contra a mudança global do clima

Aumenta a capacidade de adaptação a secas (meta 13.1) e leva alerta precoce a quem está mais exposto (meta 13.3).

10

ODS 10 — Redução das desigualdades

Leva ao agricultor familiar uma informação antes restrita à agricultura de grande escala, por canais que funcionam sem internet (meta 10.2).

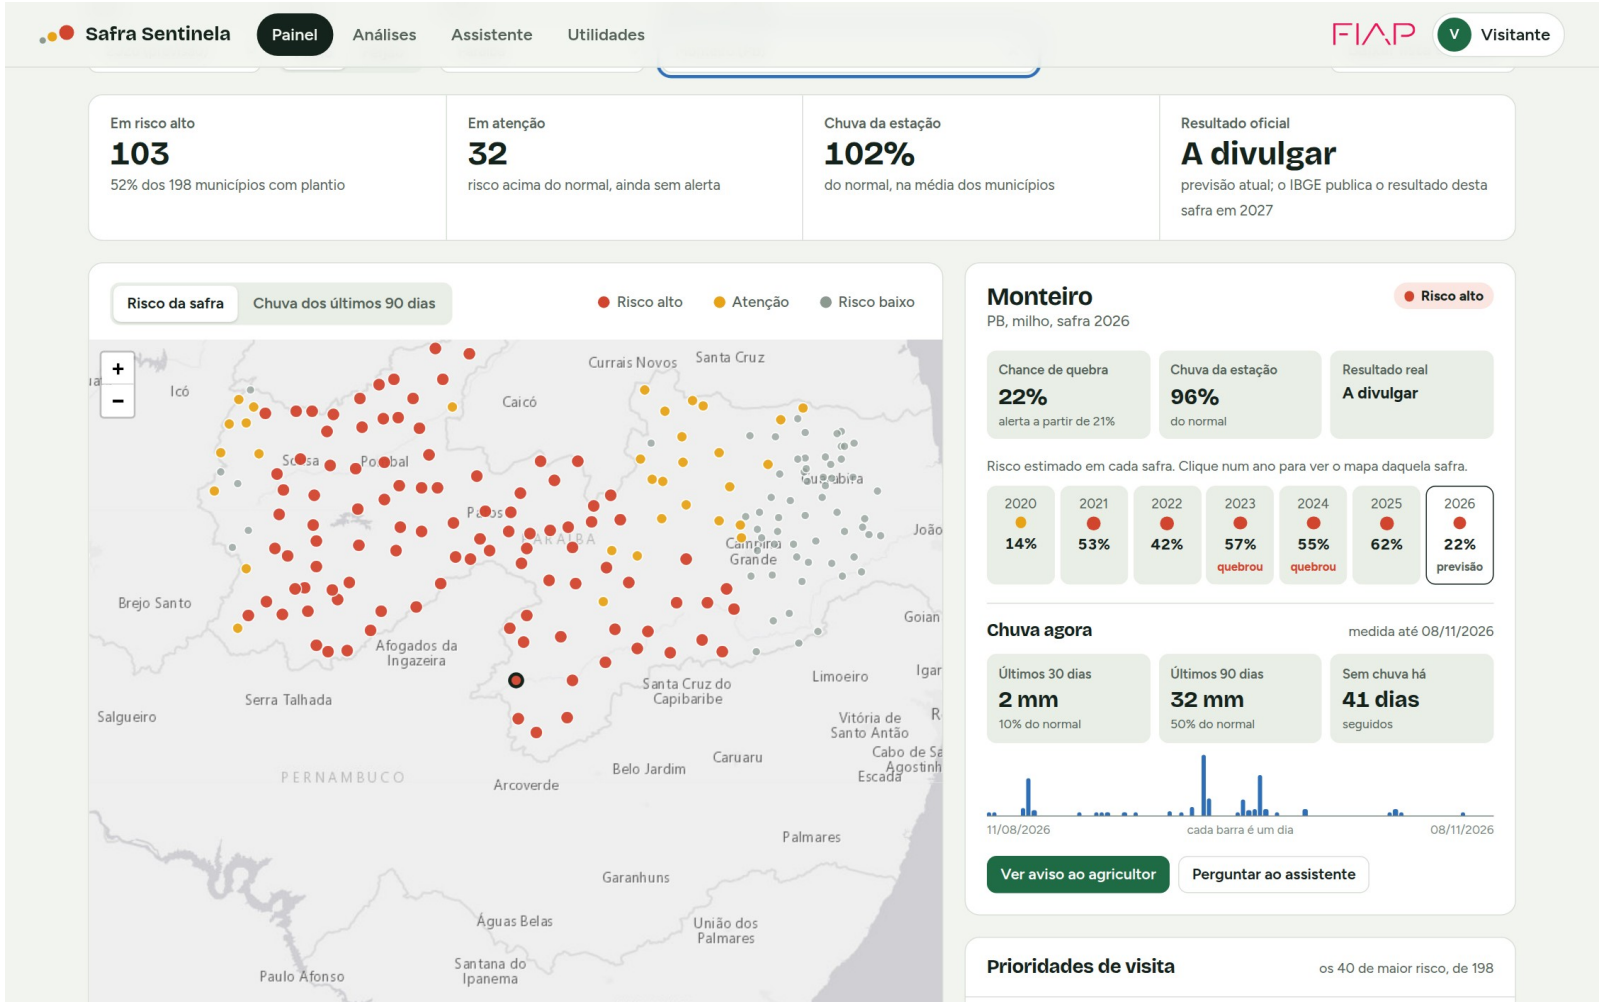
Metas citadas conforme a Agenda 2030 da ONU.

Arquitetura: o caminho do dado, da origem até o usuário



Proposta conceitual. Já implementados no protótipo: coleta, variáveis, modelo, API e plataforma web, com a chuva atualizada automaticamente. A mensageria está simulada.

Protótipo: o painel do técnico e do gestor



1

Safra 2026, previsão atual

Resumo da safra; o resultado oficial só sai no ano seguinte.

2

Mapa de risco

Cada ponto é um município, em três níveis de risco.

3

Detalhe do município

Chance de quebra, histórico das safras e a chuva de agora.

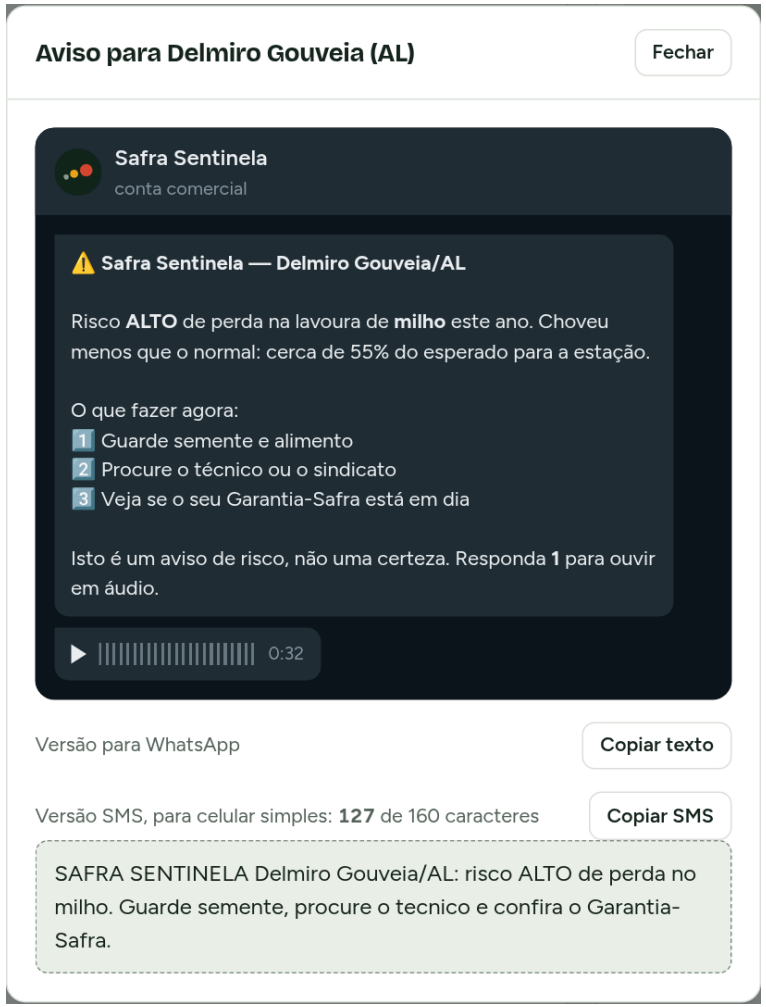
4

Filtros e busca

Safra, cultura, estado e nome do município.

Plataforma própria do Safra Sentinela, funcionando com dados reais. Na tela: Paraíba, milho, safra 2026.

Protótipo: o que chega ao celular do agricultor



COMO A MENSAGEM FOI PENSADA

Uma frase com o nível de risco e a cultura afetada.

Três ações práticas: guardar semente e alimento, procurar o técnico, conferir o Garantia-Safra.

Honesta sobre a incerteza: “é um aviso de risco, não uma certeza”.

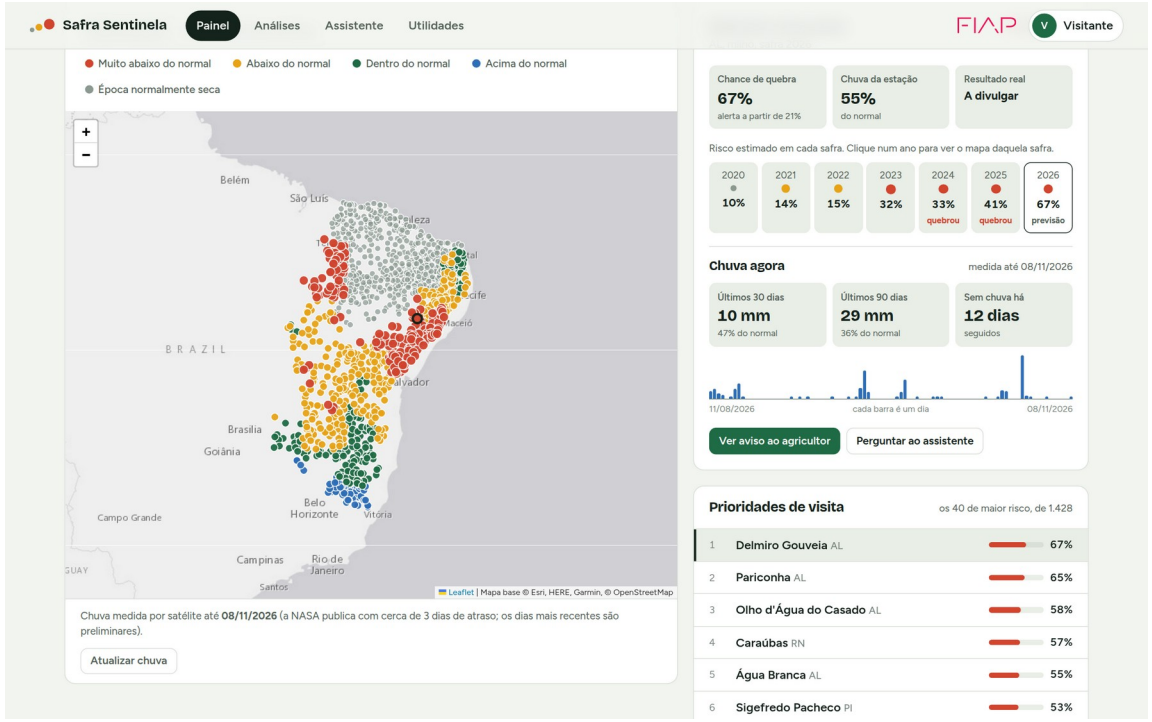
Áudio a um toque para quem não lê.

VERSÃO SMS (celular simples, sem internet)

SAFRA SENTINELA Delmiro Gouveia/AL: risco ALTO de perda no milho. Guarde semente, procure o tecnico e confira o Garantia-Safra.

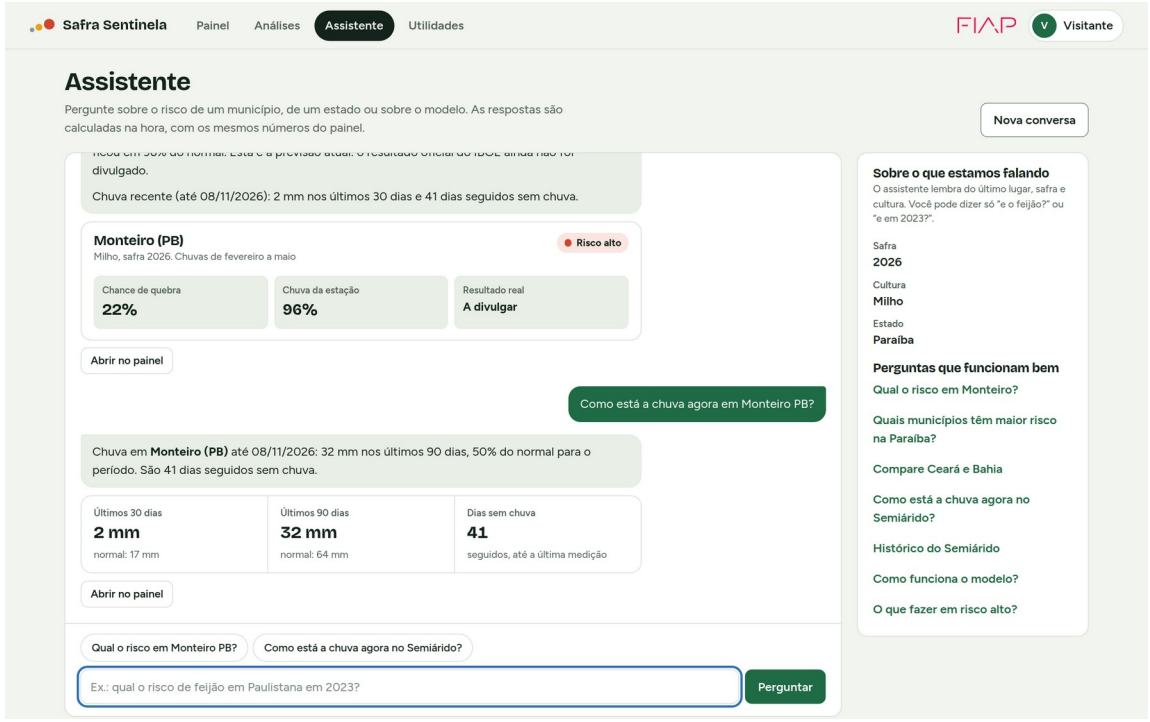
Aviso gerado pela plataforma para Delmiro Gouveia (AL), milho, safra 2026. O áudio é ilustrativo.

Protótipo: chuva quase em tempo real e assistente



Chuva dos últimos 90 dias

Cada município comparado com o normal do período, com dados até 08/11/2026. No detalhe, a chuva de cada dia e os dias seguidos sem chuva.



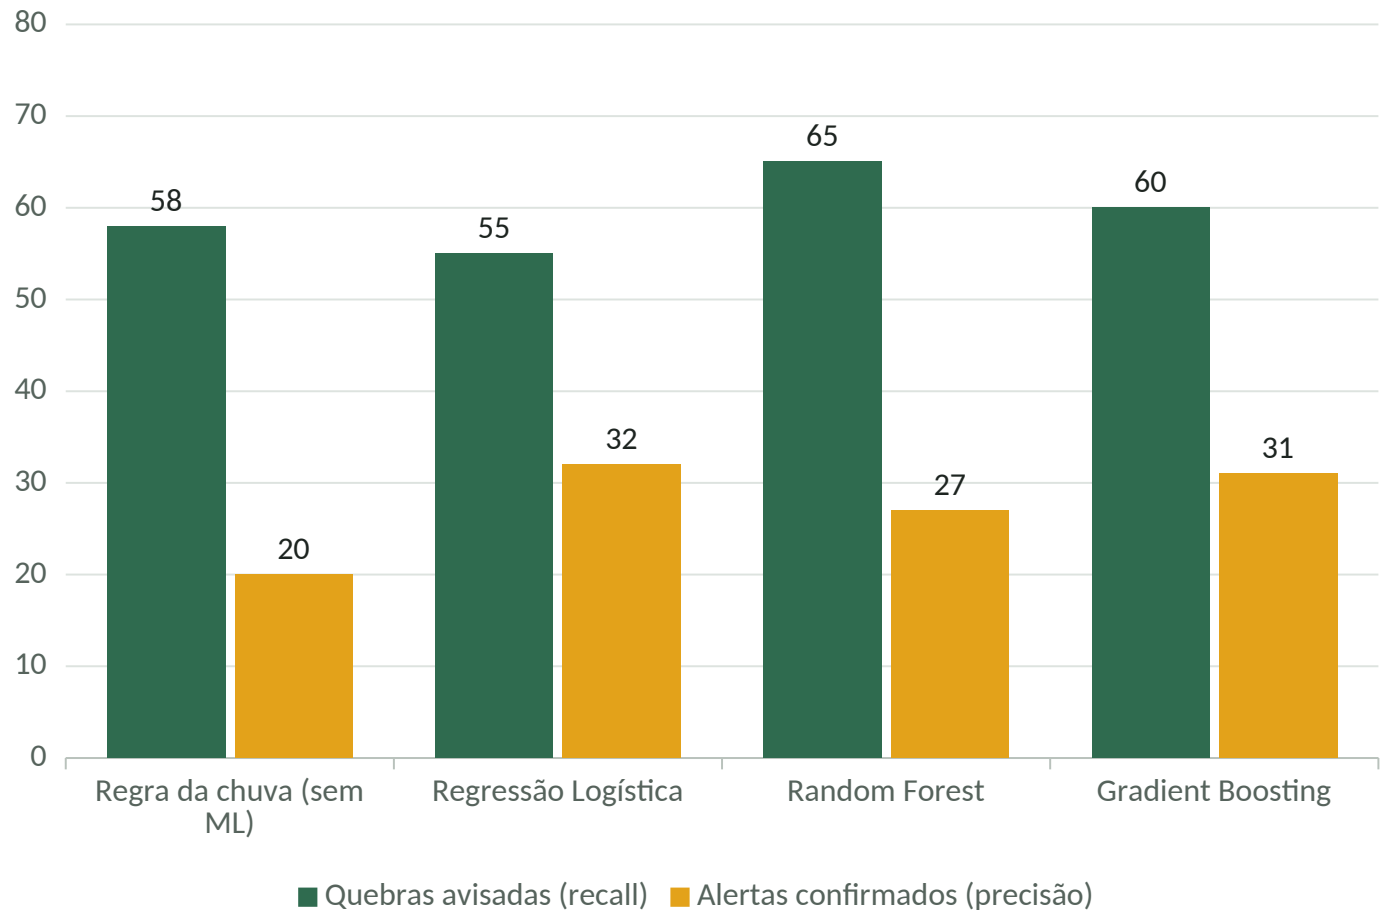
Assistente

Responde sobre risco, chuva, histórico e o modelo, e lembra do contexto da conversa. Não usa IA generativa: calcula a resposta sobre a mesma base do painel.

Chuva: NASA POWER, dados diários preliminares. Ela serve para acompanhamento e não entra no cálculo do risco.

O que o modelo consegue hoje: avisa 6 em cada 10 quebras

Desempenho no teste, safras de 2020 a 2025 (%)



60%

das quebras reais foram avisadas pelo modelo escolhido (Gradient Boosting)

1,8×

melhor que a regra simples “choveu pouco” em separar quem quebra de quem não quebra (PR-AUC)

31%

dos alertas se confirmam: por isso o aviso fala em risco, não em certeza

Treino: 2003–2019. Teste: 2020–2025, nunca visto pelo modelo. Para a safra de 2026, o mesmo modelo é reajustado com 2003–2025.

Uso responsável dos dados: privacidade, segurança e vieses

Privacidade (LGPD)

Só três dados pessoais: telefone, município e cultura

Cadastro com consentimento; sair a qualquer momento respondendo SAIR

Sem CPF, renda ou localização exata

O risco é calculado por município, com dados públicos

Segurança

Telefones guardados com criptografia

Acesso ao painel por perfil (técnico, gestor)

Dados apagados quando o agricultor sai do serviço

Registro de quem consultou o quê

Vieses encontrados

Ceará: 30% das quebras avisadas; Bahia: 77%

Lavouras menores: 49% das quebras avisadas

Feijão: 51%; milho: 68%

Antes de operar: ajustar o limiar por região e acompanhar cada grupo

Compromisso com o agricultor: todo aviso diz que é um risco, não uma certeza, e quem não tem celular é alcançado pelo rádio e pelo sindicato.

Vieses medidos no conjunto de teste (2020–2025) do modelo escolhido. O modelo usa a média do município, não a situação de cada família.



Apêndice técnico

Formulação do problema, construção das variáveis, validação, modelos e hiperparâmetros, calibração, resultados, equidade e arquitetura. Cada escolha vem com a fórmula e com o motivo.

O notebook e o README do projeto trazem o código e as mesmas contas, passo a passo.

Formulação: o que exatamente o modelo prevê

VARIÁVEL-ALVO

$$r_ref(m, c, t) = \text{média}\{\, r(m, c, t-1), \ldots, r(m, c, t-5) \,\}$$

$$quebra(m, c, t) = 1 \quad \text{se} \quad r(m, c, t) < 0{,}5 \cdot r_ref(m, c, t)$$

r: rendimento em kg/ha · m: município · c: cultura · t: ano · mínimo de 3 anos em r_ref

66.236	2003–2025	19,7%	Binária
observações (município, cultura, ano)	safras modeladas	de quebras (feijão 17,3%; milho 22,0%)	classificação supervisionada

Lavouras com plantio e colheita zero entram com r = 0, portanto como quebra: são as perdas totais, o caso mais grave. Os anos de 2000 a 2002 servem só para formar a referência.

POR QUE ESTA DEFINIÇÃO

Limite relativo. O rendimento médio varia cerca de oito vezes entre municípios. Um corte em kg/ha marcaria como quebra permanente quem produz pouco.

50%. É o gatilho de perda do Garantia-Safra: o alvo tem significado prático.

Só o passado. A referência usa anos anteriores a t. Pode ser calculada antes da safra e não vaza o alvo.

Classificação, não regressão. A decisão apoiada é binária (avisar ou não), e numa regressão o erro seria dominado pelo nível de produtividade, que é estável.

Fonte do rendimento: IBGE, Produção Agrícola Municipal, tabela SIDRA 5457.

Variáveis: 58 preditoras, alinhadas à estação chuvosa local

INÍCIO DA ESTAÇÃO CHUVOSA (janela de 4 meses mais chuvosa)

$$s^* = \operatorname{argmax}_s \sum_{k=0\ldots3} \bar{P}[(s+k) \bmod 12]$$

$\bar{P}$: chuva média de cada mês, calculada só com os anos até 2019 (treino)

"NORMAL" SEM VAZAMENTO (média expansiva dos anos anteriores)

$$N(t) = \text{média}\{\, x(\tau) : \tau < t \,\}$$

$$\text{desvio}(t) = x(t) - N(t)$$

$$\%\ \text{do normal}(t) = 100 \cdot x(t) \,/\, N(t)$$

Por que alinhar pela estação: "chuva de março" significa coisas diferentes no Ceará e em Minas. "Segundo mês de chuva" é a mesma fase da lavoura em todo o território, e um único modelo serve aos 11 estados.

Por que o normal expansivo: a média de todo o período levaria informação de anos futuros para dentro do treino.

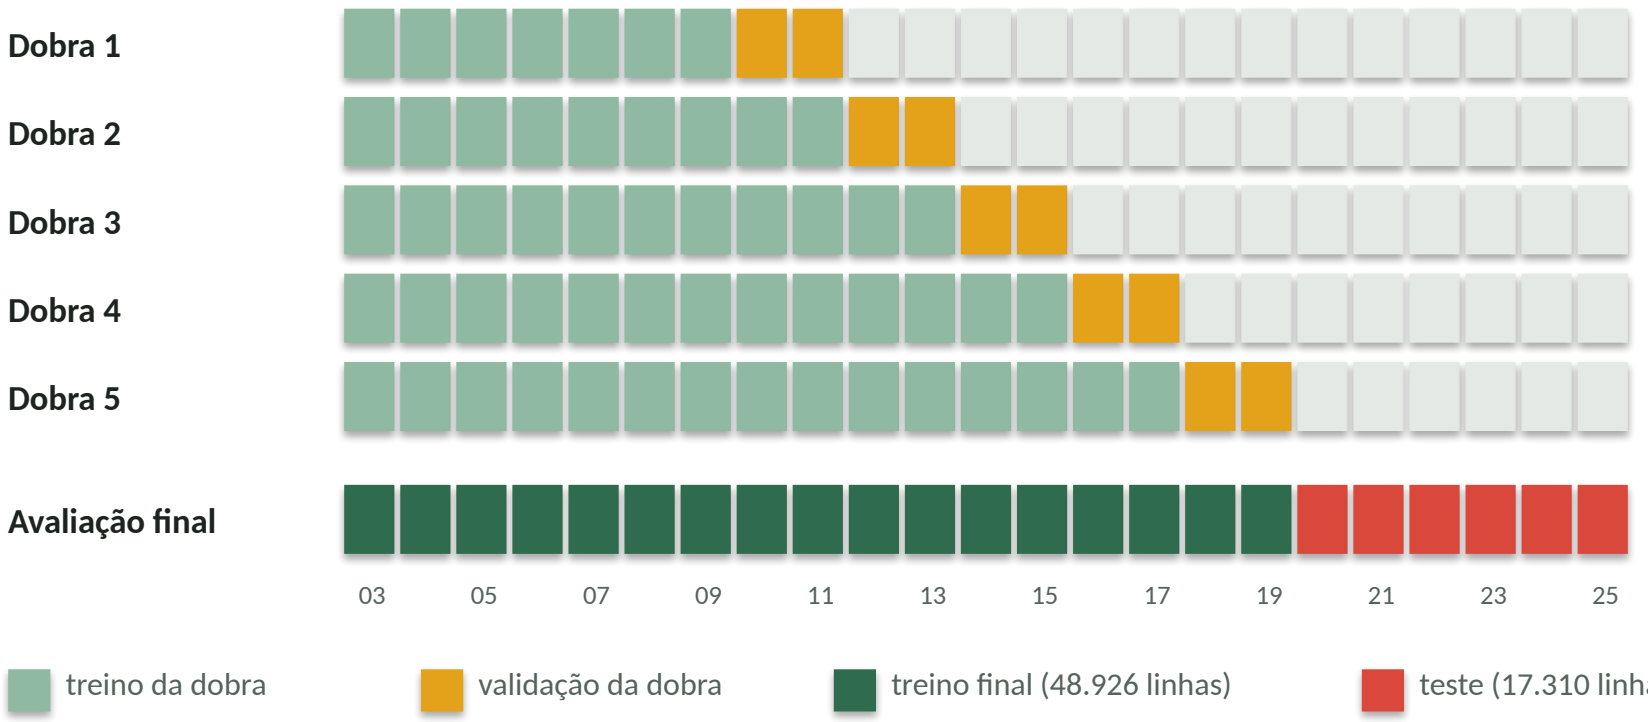
Grupo	Conteúdo	N°
Clima por mês	7 meses (3 antes + 4 da estação) × 6 medidas: chuva, desvio da chuva, umidade do solo e seu desvio, desvio da temperatura máxima, umidade do ar	42
Agregados de chuva	antes da estação, meses 1–2 e estação inteira, em mm e em % do normal	6
Histórico	rendimento de referência, do ano anterior, coeficiente de variação, quebras em 5 anos, log(1 + área plantada anterior)	5
Localização	latitude, longitude, mês de início das chuvas	3
Categóricas	cultura e estado (one-hot: 69 colunas no total)	2

Fonte do clima: NASA POWER (reanálise MERRA-2), grade de 0,5° × 0,625°. Os 1.477 municípios caem em 331 células.

Nada do ano previsto além do clima: área colhida, produção e rendimento do próprio ano não entram.

Em cada célula, os meses pre3, pre2 e pre1 antecedem o início das chuvas; m1 a m4 são a estação.

Validação: divisão cronológica e blocos de anos



Por que cronológica: a taxa de quebra vai de 5% a 60% conforme o ano. Numa divisão aleatória, o modelo aprenderia "2012 foi seco" em vez da relação entre clima e perda.

Blocos de anos inteiros: nunca se treina e valida com lavouras da mesma safra.

Pré-processamento no pipeline: imputação, padronização e codificação são ajustadas só com o treino de cada dobra.

$w_k = n / (2 \cdot n_k)$ $\quad AP = \Sigma_n (R_n - R_{n-1}) \cdot P_n$ $\quad \tau = \max\{ \tau : \text{recall}(\tau) \geq 0{,}75 \}$

pesos de classe (1 quebra para 4 normais) · PR-AUC, a métrica de seleção · limiar, com o recall medido fora da amostra

PR-AUC em vez de acurácia: prever "nunca quebra" acerta 84% do teste sem avisar ninguém.

Modelos e hiperparâmetros

	Regressão Logística	Random Forest	Gradient Boosting (escolhido)
Classe (scikit-learn 1.9)	LogisticRegression	RandomForestClassifier	HistGradientBoostingClassifier
Parâmetros fixos	penalidade L2, L-BFGS, max_iter = 2000, class_weight = balanced; variáveis padronizadas	300 árvores, Gini, bootstrap, sem limite de profundidade, class_weight = balanced_subsample	perda logarítmica, até 300 árvores, min_samples_leaf = 20, 255 faixas por variável, class_weight = balanced
Grade testada	C ∈ {0,01; 0,1; 1}	min_samples_leaf ∈ {5; 20} × max_features ∈ {√p; 0,3}	learning_rate ∈ {0,03; 0,1} × max_leaf_nodes ∈ {8; 31}
Escolhido	C = 0,01	min_samples_leaf = 5, max_features = √p (8 de 69 colunas)	learning_rate = 0,03, max_leaf_nodes = 8
PR-AUC média nas 5 dobras	0,489	0,471	0,497
Limiar (recall de 75%)	0,571	0,296	0,509

Leitura: a regressão escolheu a regularização mais forte e o boosting, a configuração mais conservadora (taxa baixa, árvores pequenas). É o comportamento esperado num problema ruidoso. O critério de escolha, a PR-AUC média das dobras, foi fixado antes de olhar o teste.

Busca em grade (GridSearchCV) com as cinco dobras temporais. Semente aleatória 42 em todos os modelos.

Como o Gradient Boosting funciona neste problema

MODELO ADITIVO

$$F_0(x) = \text{log-chance inicial}$$

$$F_k(x) = F_{k-1}(x) + \nu \cdot h_k(x) \qquad \nu = 0{,}03$$

$$p(x) = 1 \,/\, (1 + e^{\wedge}(-F_K(x))) \qquad K = 300$$

h_k: árvore de até 8 folhas, ajustada ao gradiente da perda na rodada k

PERDA LOGARÍTMICA PONDERADA

$$L = -\,\Sigma_i\, w_i \cdot [\, y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \,]$$

w_i: peso da classe da lavoura i. Quebras pesam cerca de 2,4 e safras normais, 0,63

As variáveis numéricas são discretizadas em até 255 faixas (histogramas): o treino fica rápido e os valores ausentes são tratados de forma nativa.

POR QUE ESTA CONFIGURAÇÃO

Árvores pequenas (8 folhas). Capturam interações simples, como pouca chuva com solo já seco, sem decorar os anos de treino.

Taxa de aprendizado baixa (0,03). Cada árvore corrige pouco; o conjunto generaliza melhor para anos novos.

Pesos de classe. Fazem o modelo dar a mesma atenção às quebras, que são 1 em cada 5. O efeito colateral é inflar a pontuação, corrigido depois pela calibração.

Parada antecipada. Fica ativa por padrão (10% do treino separado, paciência de 10 rodadas). Aqui o modelo usou as 300 árvores.

Por que não uma rede neural. Com 49 mil linhas tabulares e ruído alto, árvores costumam igualar ou superar redes, com muito menos ajuste.

Regressão Logística: $p = \sigma(w \cdot x + b)$, com penalidade $\|w\|^2/(2C)$. Random Forest: média de 300 árvores independentes.

Resultados no teste (2020–2025)

Modelo	Recall	Precisão	F1	Acurácia	PR-AUC	ROC-AUC	Alertadas
Regressão Logística	0,55	0,32	0,41	0,74	0,34	0,74	27%
Random Forest	0,65	0,27	0,38	0,66	0,33	0,71	39%
Gradient Boosting	**0,60**	**0,31**	**0,41**	**0,72**	**0,37**	**0,74**	**31%**
Regra da chuva	0,58	0,20	0,30	0,56	0,21	0,60	46%

Limiar fixado na validação. Taxa real de quebra no teste: 15,9%, que é a PR-AUC de um modelo sem informação.

MATRIZ DE CONFUSÃO, GRADIENT BOOSTING

10.807 normais, sem alerta	**3.751** alertas falsos
1.101 quebras sem aviso	**1.651** quebras avisadas

O aprendizado de máquina acrescenta informação. PR-AUC de 0,37, contra 0,21 da regra “choveu pouco” e 0,16 do acaso. Alertando 31% das lavouras, o modelo alcança 60% das quebras; a regra precisa alertar 46% para alcançar 58%.

Os três modelos quase empatam. O limite está nos dados (clima mensal em grade de 50 km, produção em média municipal), não no algoritmo.

O recall caiu de 75% (validação) para 60%. O limiar foi calibrado em 2010–2019, com 28% de quebras, e aplicado a um período com 16%. Em operação, ele precisa ser recalculado a cada safra.

Sem intervalos de confiança: lavouras do mesmo ano são correlacionadas, e diferenças pequenas entre modelos não são significativas.

Calibração: da pontuação à probabilidade

CALIBRAÇÃO DE PLATT (2 parâmetros, ajustados fora da amostra)

$$p = \sigma(\, a \cdot \mathrm{logit}(s) + b \,) \qquad a = 0{,}871 \quad b = -1{,}118$$

s: pontuação do modelo · $\mathrm{logit}(s) = \ln(s / (1 - s))$ · σ: função logística

COMO SE MEDE

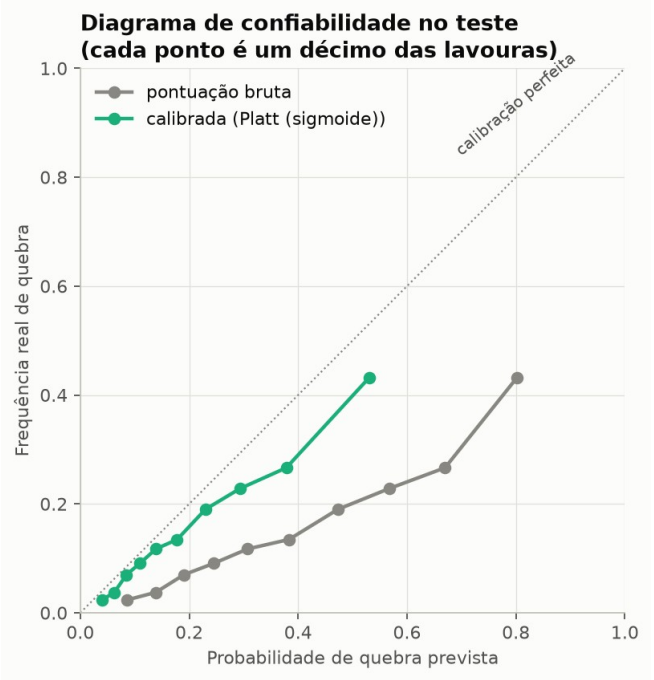
$$\mathrm{Brier} = (1/n)\, \Sigma_i\, (p_i - y_i)^2$$

$$\mathrm{ECE} = \Sigma_g\, (n_g / n) \cdot |\, \bar{y}_g - \bar{p}_g \,|$$

g: dez grupos de mesmo tamanho, ordenados pela probabilidade prevista

No teste	Pontuação bruta	Calibrada
Probabilidade média prevista (real: 16%)	39%	20%
Brier (referência: 0,136)	0,184	0,122
Erro de calibração (ECE)	0,227	0,046

Brier de referência: prever para todas as lavouras a taxa de quebra do treino (21%).



Por que Platt: é crescente, então não muda a ordem das lavouras nem o alerta.

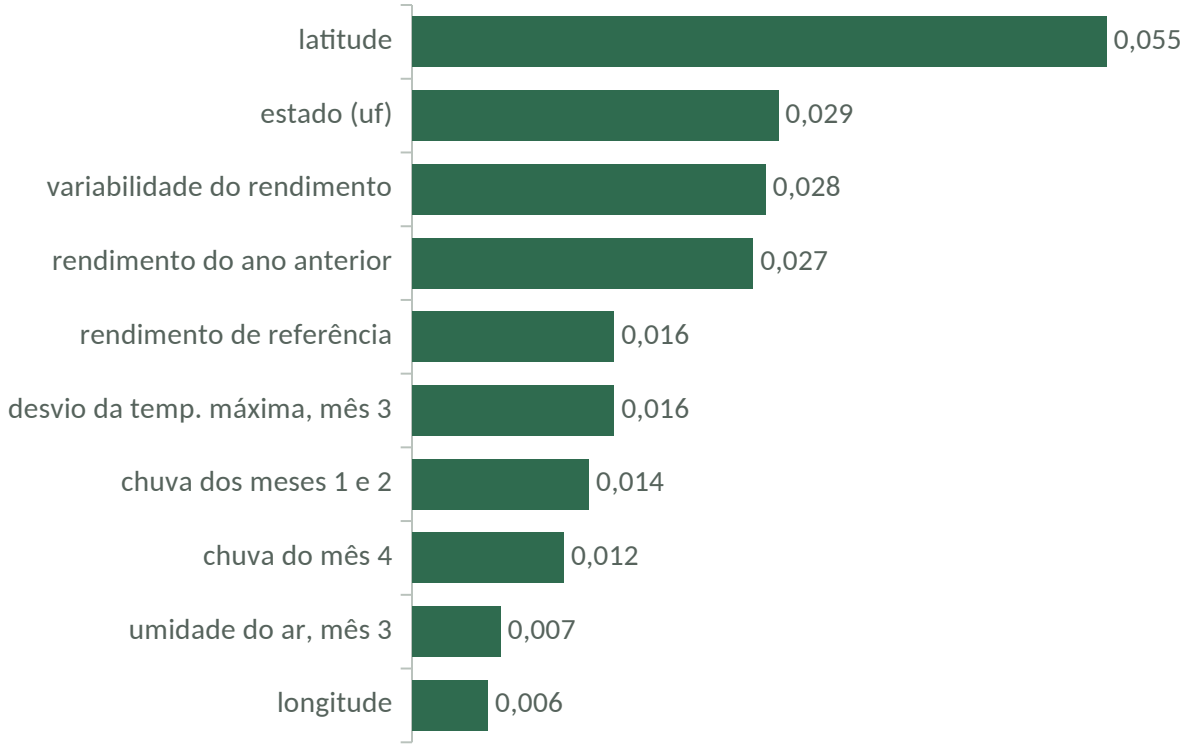
Escolha do método. Platt e isotônica foram comparadas dentro do treino, calibrando nos blocos anteriores e medindo o Brier no seguinte.

O que ainda sobra. No décimo de maior risco, a previsão média é 53% e 43% quebraram: a calibração foi aprendida num período com mais quebras.

Limiar em probabilidade. O alerta sai a partir de 25% de chance de quebra.

O que o modelo usa e com quanta antecedência avisa

Importância por permutação: queda na PR-AUC do teste



Cada variável é embaralhada 5 vezes no teste. Ao contrário da importância interna das árvores, a permutação mede o efeito em dados novos e não favorece variáveis com muitos valores distintos.

Antecedência: o mesmo modelo com menos informação

Cenário	Informação	Recall	Precisão	PR-AUC
A, antes do plantio	histórico + 3 meses antes das chuvas	0,74	0,20	0,25
B, meio da estação	A + 2 primeiros meses de chuva	0,74	0,24	0,29
C, fim da estação	**B + 2 últimos meses de chuva**	**0,60**	**0,31**	**0,37**

Quem e quando. Localização e histórico dizem quem é vulnerável (0,091 e 0,071 somados por grupo); o clima da estação diz quando (0,055). O clima antes das chuvas não ajuda (−0,006).

Atenção ao peso da localização. Parte do aprendido é “nesta região costuma quebrar”, o que ajuda a explicar o desempenho desigual entre estados.

Antecedência custa. Dois terços do ganho vêm dos dois últimos meses de chuva. O aviso confiável sai no fim da estação; para antes do plantio, seria preciso previsão climática sazonal.

Variáveis de clima são correlacionadas entre si, e a permutação tende a subestimar cada uma isoladamente.

Equidade entre grupos e limites estatísticos

Grupo (teste)	Lavouras	Quebras	Recall	Precisão
Bahia	3.376	15%	77%	22%
Paraíba	2.376	28%	75%	44%
Piauí	2.592	19%	65%	32%
Pernambuco	1.490	17%	57%	29%
Rio Grande do Norte	1.743	21%	46%	41%
Ceará	2.100	16%	30%	27%
Menores áreas (1° quartil)	4.328	11%	49%	29%
Maiores áreas (4° quartil)	4.325	18%	58%	30%
Feijão	8.684	15%	51%	30%
Milho	8.626	16%	68%	31%

Ceará e Bahia tiveram taxas de quebra parecidas, mas o modelo avisou 30% das quebras cearenses e 77% das baianas.

Estados com menos de 250 quebras no teste foram omitidos da tabela. Quartis pela área plantada no ano anterior.

O QUE OS NÚMEROS NÃO PERMITEM AFIRMAR

Sem intervalos de confiança. Lavouras vizinhas no mesmo ano são correlacionadas; o tamanho efetivo da amostra é bem menor que 17 mil.

Poucos anos independentes. Seis safras no teste e dez na validação. Um ano atípico muda as métricas.

Alvo com ruído. O rendimento municipal é estimado por agentes do IBGE e mistura sequeiro com irrigação.

Resolução. Clima mensal em grade de 50 km não vê veranicos nem chuvas localizadas.

Calendário fixo. A estação chuvosa foi definida com a média até 2019 e não se adapta a anos de chuva atrasada.

Antes de operar: limiar por região, acompanhamento do recall por grupo e recalibração a cada safra.

Safra de 2026 e chuva recente: como são calculadas

PREVISÃO DA SAFRA DE 2026

1. Conferência. O script refaz as variáveis fora do notebook, treina com 2003–2019 e compara as 17.310 probabilidades do teste: maior diferença de 0,00005.

2. Limiar. Sete blocos fora da amostra, de 2012 a 2025, com a mesma regra de 75% de recall: τ = 0,472.

3. Calibração. Curva de Platt ajustada nas mesmas previsões fora da amostra. Em probabilidade, o alerta sai a partir de 21%.

4. Reajuste. Mesmos hiperparâmetros, todas as safras conhecidas (2003–2025). 2.869 lavouras previstas, 31% em risco alto.

Bloco fora da amostra	Quebras avisadas	Alertas confirmados
2012–2013	87%	64%
2014–2015	87%	31%
2016–2017	76%	40%
2018–2019	55%	28%
2020–2021	70%	18%
2022–2023	54%	27%
2024–2025	65%	44%

CHUVA RECENTE (NASA POWER, DIÁRIO)

$$\text{normal} = \Sigma_d \ \bar{P}[\text{mês}(d)] \ / \ \text{dias}(\text{mês}(d))$$

$$\%\ \text{do normal} = 100 \cdot \text{chuva}(90\ \text{dias}) \ / \ \text{normal}$$

d: cada dia da janela. O normal mensal é rateado pelos dias

Classes do mapa. Menos de 50% (muito abaixo), 50–80% (abaixo), 80–120% (normal), mais de 120% (acima).

Época seca. Normal menor que 0,55 mm por dia: não se compara, porque dividir por quase zero não faz sentido.

Dias sem chuva. Dias seguidos com menos de 1 mm, até a última medição.

Por que não entra no modelo. Os dias recentes vêm de um produto preliminar. No ponto de teste, a umidade do solo caiu de 0,57 para 0,35 na troca de produto: uma descontinuidade que não é física.

A previsão de 2026 só poderá ser conferida quando o IBGE publicar o resultado, em 2027. Chuva medida até 08/11/2026.

Arquitetura técnica da plataforma

Fora de linha (scripts Python)

coletar_dados.py: API SIDRA e NASA POWER, com cache e novas tentativas

Notebook de ML: pandas e scikit-learn: variáveis, validação, modelos, calibração

atualizar_clima.py: clima consolidado do ano corrente

prever_safra_atual.py: conferência com o notebook, limiar, calibração e previsão

preparar_app.py: gera os CSVs que a plataforma lê

Servidor (FastAPI + Uvicorn)

dados.py: CSVs (3 MB) carregados uma vez em memória; consultas são filtros sobre listas

clima.py: chuva diária da NASA: 6 conexões, gravação atômica, trava, atualização a cada 12 h

chat.py: assistente por regras: entidades, 11 intenções e contexto

auth.py: PBKDF2-HMAC-SHA256 (200 mil iterações); cookie assinado com HMAC, 8 horas

API REST em JSON: risco, município, análises, chuva, chat e exportação em CSV

Navegador (HTML, CSS e JavaScript)

Módulos nativos, sem build: cada página é carregada sob demanda; navegação por hash

Leaflet 1.9 (canvas): 1.400 pontos com fluidez; dois modos de mapa

Chart.js 4.5: gráficos com filtro cruzado por estado

Simulador de limiar: histograma em 100 faixas; recall e precisão por soma acumulada, sem nova chamada

Preferências: filtros compartilhados, tema claro ou escuro e tamanho do texto

Decisões de engenharia: o servidor não treina nem carrega o modelo (as previsões chegam prontas dos scripts); não há banco de dados; se a NASA estiver fora do ar, a chuva anterior é mantida; e a chuva recente nunca alimenta o risco.

Dependências do servidor: FastAPI e Uvicorn. Tudo o mais usa a biblioteca padrão do Python.

Os satélites já veem a seca chegar.
O Safra Sentinela faz o aviso chegar a quem planta.

VÍDEO PITCH

[inserir aqui o link público do YouTube]

Safra Sentinela · Grupo RHEAL · Turma 2TSCOA · Global Solution 2026/2 — CitizenTech